# Introdução a dados relacionais

Benilton Carvalho, Guilherme Ludwig

# Dados em múltiplas tabelas

- É comum que dados estejam guardados em múltiplas tabelas. Esse modelo de banco de dados é conhecido como *Modelo Relacional* (https://en.wikipedia.org/wiki/Relational_model), em que os dados são acessados através de um *nome de tabela*, uma *chave* (*key*) e uma *coluna* (*features*).

- Se espera que, em no mínimo uma tabela, a chave identifique unicamente cada observação.

- O material da aula é baseado no capítulo 13 do livro *R for Data Science* (Wickham & Grolemund, 2017). Leiam o capítulo para verem exemplos adicionais: http://r4ds.had.co.nz/relational-data.html

# Exemplo

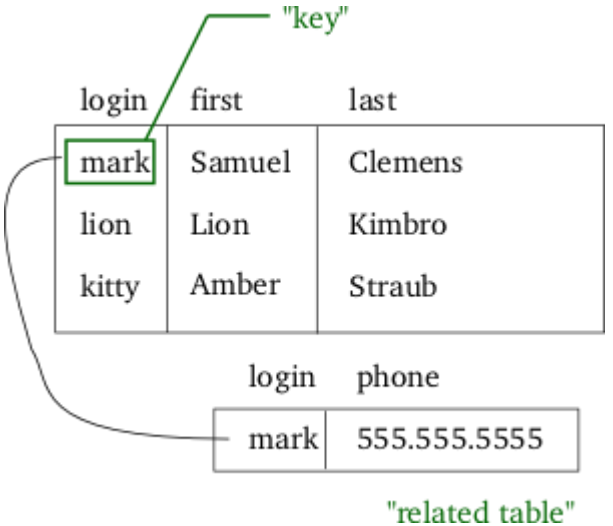


Exemplo de base relacional:

Figura de https://en.wikipedia.org/wiki/Relational_model

# Consultas

- Cada tabela, separadamente, funciona como os bancos de dados com que trabalhamos até agora.
- Uma coluna em comum entre as tabelas será usada como chave, ligando a informação de cada linha. Porém, não há garantias que o valor seja único, nem sempre qual coluna servirá de chave é óbvio.
- Uma *consulta* (ou *query*) é um pedido do usuário ao *relational database management system* (RDBMS) que une informações de um grupo de indivíduos (baseados na chave) ao longo de várias tabelas.
- Nós vamos, primeiramente, examinar a operação *join*, do pacote `dplyr`, para realizar consultas em pares de tabelas.

# Exemplo

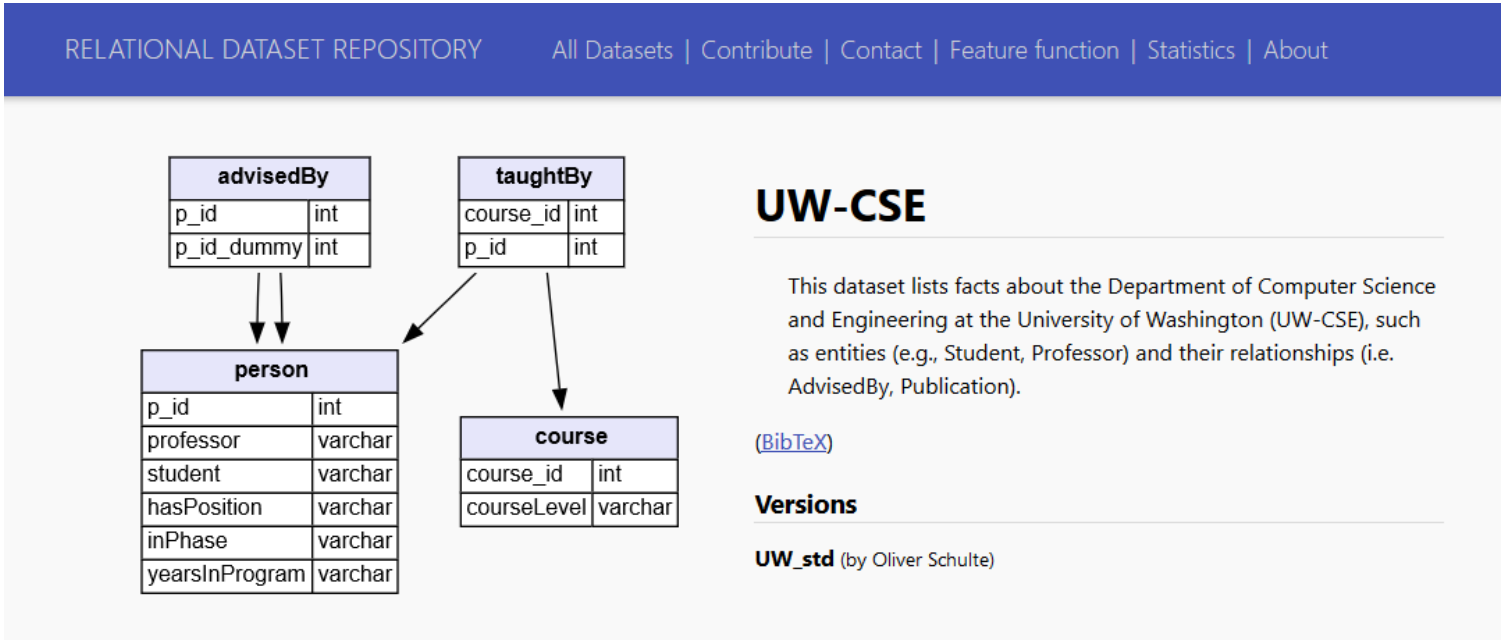


Professores e alunos da University of Washington, ciência da computação.

Dados: https://relational.fit.cvut.cz/dataset/UW-CSE

Explicação: http://aiweb.cs.washington.edu/ai/mln/database.html

# Recuperando dados do MySQL server

Código apenas para a reprodução do exemplo. SQL será abordado só em aulas futuras.

```
library(RMySQL)
mydb <- dbConnect(MySQL(), user='guest', password='relational',
                  dbname='UW_std', port = 3306,
                  host='relational.fit.cvut.cz')
rs <- dbSendQuery(mydb, "SELECT * FROM advisedBy")
advisedBy <- fetch(rs, n=-1)
rs <- dbSendQuery(mydb, "SELECT * FROM course")
course <- fetch(rs, n=-1)
rs <- dbSendQuery(mydb, "SELECT * FROM person")
person <- fetch(rs, n=-1)
rs <- dbSendQuery(mydb, "SELECT * FROM taughtBy")
taughtBy <- fetch(rs, n=-1)
dbDisconnect(mydb)
write.csv(advisedBy, "a03-advisedBy.csv", row.names = FALSE)
write.csv(course, "a03-course.csv", row.names = FALSE)
write.csv(person, "a03-person.csv", row.names = FALSE)
write.csv(taughtBy, "a03-taughtBy.csv", row.names = FALSE)
```

# advisedBy

```
advisedBy %>% as_tibble
```

```
## # A tibble: 113 x 2
##      p_id p_id_dummy
##     <int>      <int>
##  1    96          5
##  2   118          5
##  3   183          5
##  4   263          5
##  5   362          5
##  6   266          7
##  7   272          7
##  8     6         29
##  9   242         29
## 10   303         29
## # … with 103 more rows
```

`p_id` orienta `p_id_dummy`.

# course

```
course %>% as_tibble
```

```
## # A tibble: 132 x 2
##    course_id courseLevel
##        <int> <fct>
##  1         5 Level_300
##  2        11 Level_300
##  3        18 Level_300
##  4       104 Level_300
##  5       124 Level_300
##  6       146 Level_300
##  7       147 Level_300
##  8       165 Level_300
##  9         8 Level_400
## 10        20 Level_400
## # … with 122 more rows
```

`level_100` (introdução), `level_300` (graduação, segundo ano), `level_400` (graduação, avançado) e `level_500` (pós-graduação).

# taughtBy

```
taughtBy %>% as_tibble
```

```
## # A tibble: 189 x 2
##    course_id  p_id
##        <int> <int>
##  1         0    40
##  2         1    40
##  3         2   180
##  4         3   279
##  5         4   107
##  6         7   415
##  7         8   297
##  8         9   235
##  9        11    52
## 10        11    57
## # … with 179 more rows
```

Qual curso em `course_id` e `p_id` de quem ensinou.

# person

```
person %>% as_tibble
```

```
## # A tibble: 278 x 6
##     p_id professor student hasPosition inPhase       yearsInProgram
##    <int>     <int>   <int> <fct>       <fct>         <fct>
##  1     3         0       1 0           0             0
##  2     4         0       1 0           0             0
##  3     5         1       0 Faculty     0             0
##  4     6         0       1 0           Post_Quals    Year_2
##  5     7         1       0 Faculty_adj 0             0
##  6     9         0       1 0           Post_Generals Year_5
##  7    13         0       1 0           Post_Generals Year_7
##  8    14         0       1 0           Post_Generals Year_10
##  9    15         0       1 0           Post_Quals    Year_3
## 10    18         0       1 0           Pre_Quals     Year_3
## # … with 268 more rows
```

# Tabelas não são 1-1

```
# Same course, different faculty
taughtBy %>% filter(course_id == 11)
```

```
##   course_id p_id
## 1        11   52
## 2        11   57
## 3        11  298
## 4        11  324
## 5        11  331
```

```
# Same faculty, different course
taughtBy %>% filter(p_id == 40)
```

```
##   course_id p_id
## 1         0   40
## 2         1   40
```

- `p_id` identifica indivíduos unicamente em `person`;
- `course_id` identifica cursos unicamente em `courses`.

# Objetivo da aula de hoje

- Como relacionar informação de diferentes tabelas?
- Por exemplo, é mais comum que professores adjuntos ensinem classes de pós-graduação?
- Nós sabemos trabalhar com tabelas isoladas. Para duas ou mais tabelas, consideraremos funções do tipo **JOIN**.
- Primeiramente, consideraremos os chamados **mutating joins**, que combinam variáveis de diferentes tabelas.

# Tipos de JOIN: setup

Usando os diagramas de Wickham and Grolemund (2017), considere dados de duas tabelas:

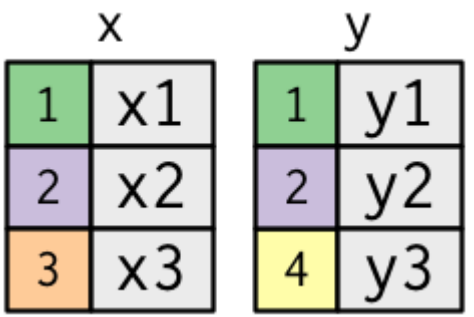


A coluna colorida é a chave, `x` e `y` são colunas, tomando valores `x1`, `x2`, etc.

# Tipos de JOIN: setup 2

```
(x <- data.frame(key = c(1,2,3), val_x = c("x1","x2","x3")))
```

```
##   key val_x
## 1   1    x1
## 2   2    x2
## 3   3    x3
```

```
(y <- data.frame(key = c(1,2,4), val_y = c("y1","y2","y4")))
```

```
##   key val_y
## 1   1    y1
## 2   2    y2
## 3   4    y4
```

# INNER JOIN: inner_join

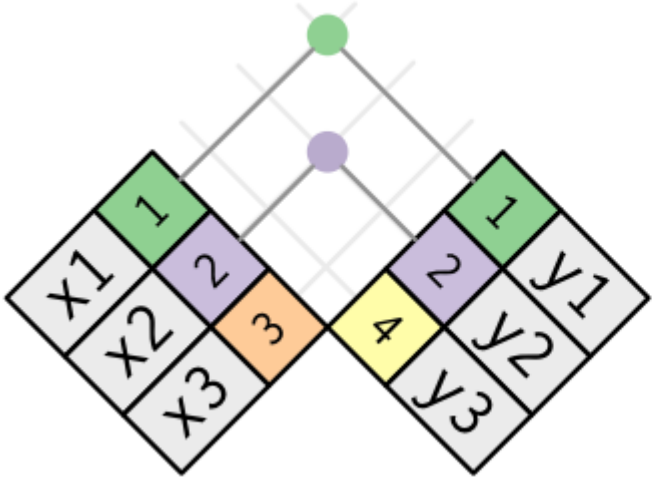


| key | val_x | val_y |
|---|---|---|
| 1 | x1 | y1 |
| 2 | x2 | y2 |

# INNER JOIN: inner_join

```
x %>% inner_join(y, by = "key")
```

```
##   key val_x val_y
## 1   1    x1    y1
## 2   2    x2    y2
```

# OUTER JOIN: left_join

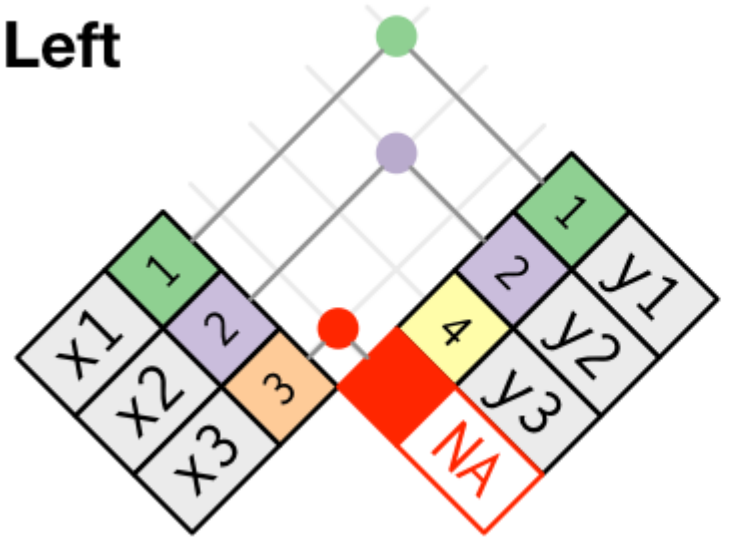


| key | val_x | val_y |
|---|---|---|
| 1 | x1 | y1 |
| 2 | x2 | y2 |
| 3 | x3 | NA |

# OUTER JOIN: left_join

```
x %>% left_join(y, by = "key")
```

```
##   key val_x val_y
## 1   1    x1    y1
## 2   2    x2    y2
## 3   3    x3  <NA>
```

# OUTER JOIN: right_join

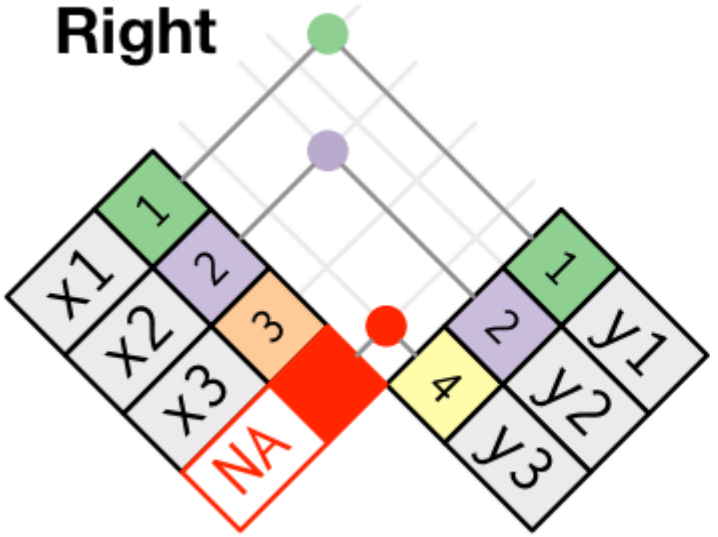


| key | val_x | val_y |
|---|---|---|
| 1 | x1 | y1 |
| 2 | x2 | y2 |
| 4 | NA | y3 |

# OUTER JOIN: right_join

```
x %>% right_join(y, by = "key")
```

```
##   key val_x val_y
## 1   1    x1    y1
## 2   2    x2    y2
## 3   4  <NA>    y4
```

# OUTER JOIN: full_join

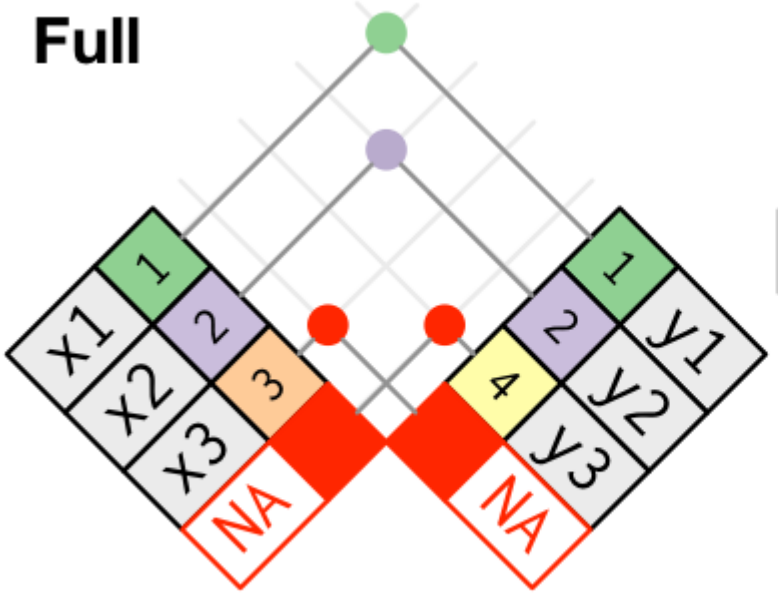


| key | val_x | val_y |
|---|---|---|
| 1 | x1 | y1 |
| 2 | x2 | y2 |
| 3 | x3 | NA |
| 4 | NA | y3 |

# OUTER JOIN: full_join

```
x %>% full_join(y, by = "key")
```

```
##   key val_x val_y
## 1   1    x1    y1
## 2   2    x2    y2
## 3   3    x3  <NA>
## 4   4  <NA>    y4
```

# Exemplo: que professores dão quais aulas?

Todos os professores de todos os cursos:

```
person %>% right_join(taughtBy, by = "p_id") %>% as_tibble
```

```
## # A tibble: 189 x 7
##     p_id professor student hasPosition inPhase yearsInProgram course_id
##    <int>     <int>   <int> <fct>       <fct>   <fct>                <int>
##  1    40         1       0 Faculty     0       0                        0
##  2    40         1       0 Faculty     0       0                        1
##  3   180         1       0 Faculty     0       0                        2
##  4   279         1       0 Faculty     0       0                        3
##  5   107         1       0 Faculty     0       0                        4
##  6   415         1       0 Faculty     0       0                        7
##  7   297         1       0 Faculty_eme 0       0                        8
##  8   235         1       0 Faculty     0       0                        9
##  9    52         1       0 Faculty     0       0                       11
## 10    57         1       0 0           0       0                       11
## # … with 179 more rows
```

# Exemplo: que professores dão quais aulas?

Agora vou incluir o nível do curso.

```
person %>%
  right_join(taughtBy, by='p_id') %>%
  left_join(course, by='course_id') %>%
  as_tibble() %>% select(-professor, -student)
```

```
## # A tibble: 189 x 6
##     p_id hasPosition inPhase yearsInProgram course_id courseLevel
##    <int> <fct>       <fct>   <fct>                <int> <fct>
##  1    40 Faculty     0       0                        0 Level_500
##  2    40 Faculty     0       0                        1 Level_500
##  3   180 Faculty     0       0                        2 Level_500
##  4   279 Faculty     0       0                        3 Level_500
##  5   107 Faculty     0       0                        4 Level_500
##  6   415 Faculty     0       0                        7 Level_500
##  7   297 Faculty_eme 0       0                        8 Level_400
##  8   235 Faculty     0       0                        9 Level_500
##  9    52 Faculty     0       0                       11 Level_300
## 10    57 0           0       0                       11 Level_300
## # … with 179 more rows
```

# Exemplo: que professores dão quais aulas?

Alguns estudantes ensinam classes avançadas.

```
person %>% right_join(taughtBy, by='p_id') %>%
  left_join(course, by='course_id') %>%
  filter(student == 1) %>%
  as_tibble() %>% select(-professor)
```

```
## # A tibble: 9 x 7
##    p_id student hasPosition inPhase    yearsInProgram course_id courseLeve
##   <int>   <int> <fct>       <fct>      <fct>                <int> <fct>
## 1    99       1 0           Post_Quals Year_2                  21 Level_400
## 2   204       1 0           Post_Gene… Year_6                  38 Level_400
## 3   255       1 0           Post_Gene… Year_5                  38 Level_400
## 4   263       1 0           Post_Gene… Year_6                  49 Level_400
## 5    18       1 0           Pre_Quals  Year_3                  51 Level_400
## 6     9       1 0           Post_Gene… Year_5                 124 Level_300
## 7   278       1 0           Pre_Quals  Year_2                 144 Level_500
## 8    75       1 0           Post_Gene… Year_6                 165 Level_300
## 9   141       1 0           Post_Gene… Year_6                 165 Level_300
```

# Exemplo: que professores dão quais aulas?

```
person %>% right_join(taughtBy, by='p_id') %>%
  left_join(course, by='course_id') %>%
  filter(student == 0) %>% group_by(hasPosition, courseLevel) %>%
  tally()
```

```
## # A tibble: 12 x 3
## # Groups:   hasPosition [5]
##    hasPosition courseLevel     n
##    <fct>       <fct>       <int>
##  1 0           Level_300       9
##  2 0           Level_400       7
##  3 0           Level_500       3
##  4 Faculty     Level_300      17
##  5 Faculty     Level_400      54
##  6 Faculty     Level_500      80
##  7 Faculty_adj Level_400       2
##  8 Faculty_aff Level_400       1
##  9 Faculty_aff Level_500       2
## 10 Faculty_eme Level_300       1
## 11 Faculty_eme Level_400       3
## 12 Faculty_eme Level_500       1
```

# Duplicated keys

Como nós vimos no exemplo dos professores, chaves duplicadas em uma tabela não causam problema, desde que você escolha um join apropriado.

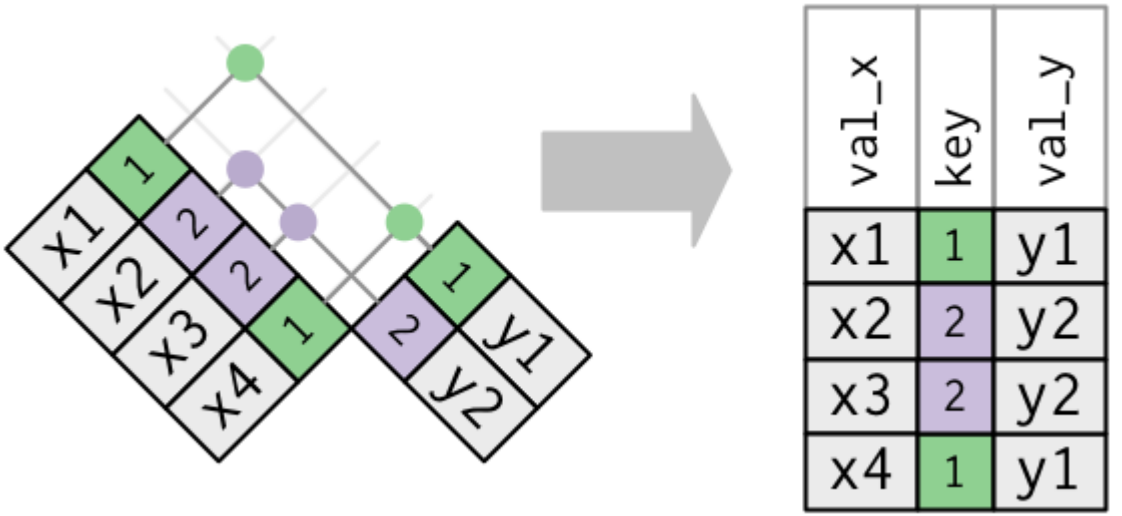


| val_x | key | val_y |
|---|---|---|
| x1 | 1 | y1 |
| x2 | 2 | y2 |
| x3 | 2 | y2 |
| x4 | 1 | y1 |

Quando as chaves são únicas, elas são chamadas de **primary keys**; se há entradas repetidas, elas são chamadas de **foreign keys**. Os valores associados a primary keys são repetidos na tabela final.

# Duplicated keys

Quando há mais de uma entrada para as duas tabelas, é executado um produto cartesiano das entradas.

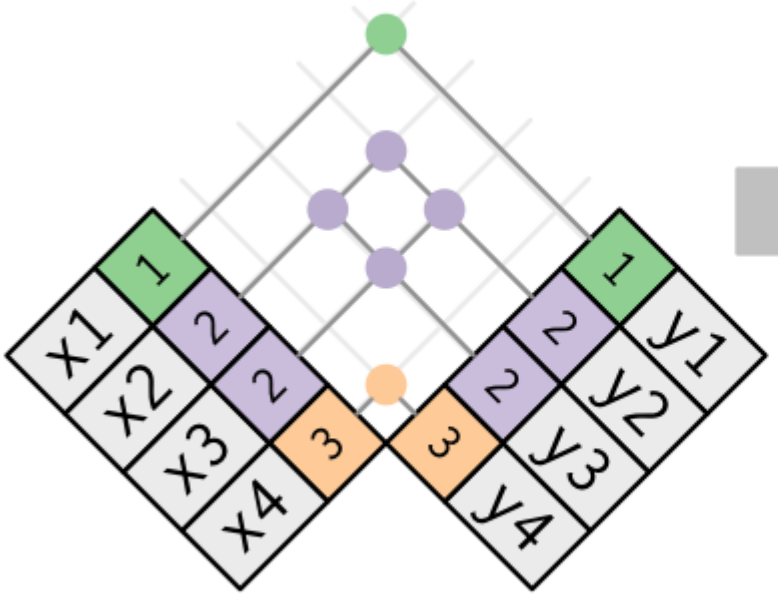


| key | val_x | val_y |
|---|---|---|
| 1 | x1 | y1 |
| 2 | x2 | y2 |
| 2 | x2 | y3 |
| 2 | x3 | y2 |
| 2 | x3 | y3 |
| 3 | x4 | y4 |

Evite joins assim. Em tese, as bases relacionais devem ter pelo menos uma chave que unicamente determina as observações em cada tabela.

# Sintaxe do parâmetro "by"

A ação padrão das funções `*_join(x, y)` no `dplyr` é `by = NULL`, que realiza o join pela combinação de *todas* as colunas com nomes idênticos em x e y. Isso pode ser perigoso!

```
x$newCol <- c(1, 1, 2)
y$newCol <- c(1, 2, 2)
full_join(x, y)
```

```
## Joining, by = c("key", "newCol")
```

```
##   key val_x newCol val_y
## 1   1    x1      1    y1
## 2   2    x2      1  <NA>
## 3   3    x3      2  <NA>
## 4   2  <NA>      2    y2
## 5   4  <NA>      2    y4
```

```
x$newCol <- NULL
y$newCol <- NULL
```

# Sintaxe do parâmetro "by"

Já `by = "colName"` une as observações pelo "colName" especificado.

```
full_join(x, y, by = "key")
```

```
##   key val_x val_y
## 1   1    x1    y1
## 2   2    x2    y2
## 3   3    x3  <NA>
## 4   4  <NA>    y4
```

Caso você queira comparar diferentes colunas, a sintaxe é `by = c("colunaX" = "colunaY")`. Note que o `R` remove `key` de `y` sem avisar!

```
x$newKey <- c(1,4,2)
full_join(x, y, by = c("newKey" = "key"))
```

```
##   key val_x newKey val_y
## 1   1    x1      1    y1
## 2   2    x2      4    y4
## 3   3    x3      2    y2
```

# Filtering joins

Há dois importantes filtering joins:

- `semi_join(x, y)` mantém todas as observações em `x` que estão presentes em `y`.
- `anti_join(x, y)` remove todas as observações em `x` que estão presentes em `y`.

Esses `*_join` retornam tabelas `x` filtradas, e não unem `x` e `y`.

# semi_join

`semi_join(x,y)` só retorna elementos de `x` que também estão em `y`

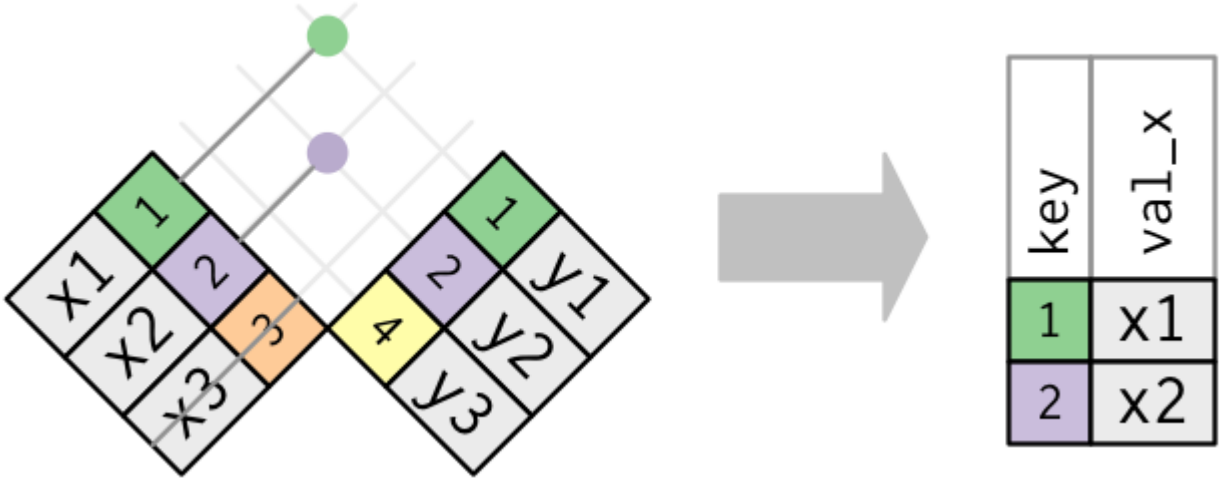


Exemplo:

```
all.equal(x %>% semi_join(y,  by = "key"),
          x %>% filter(key %in% y$key))
```

```
## [1] TRUE
```

# semi_join: duplicated keys

Não há problema se as chaves forem duplicadas para o `semi_join`, isto é, o `semi_join` não duplica as linhas.

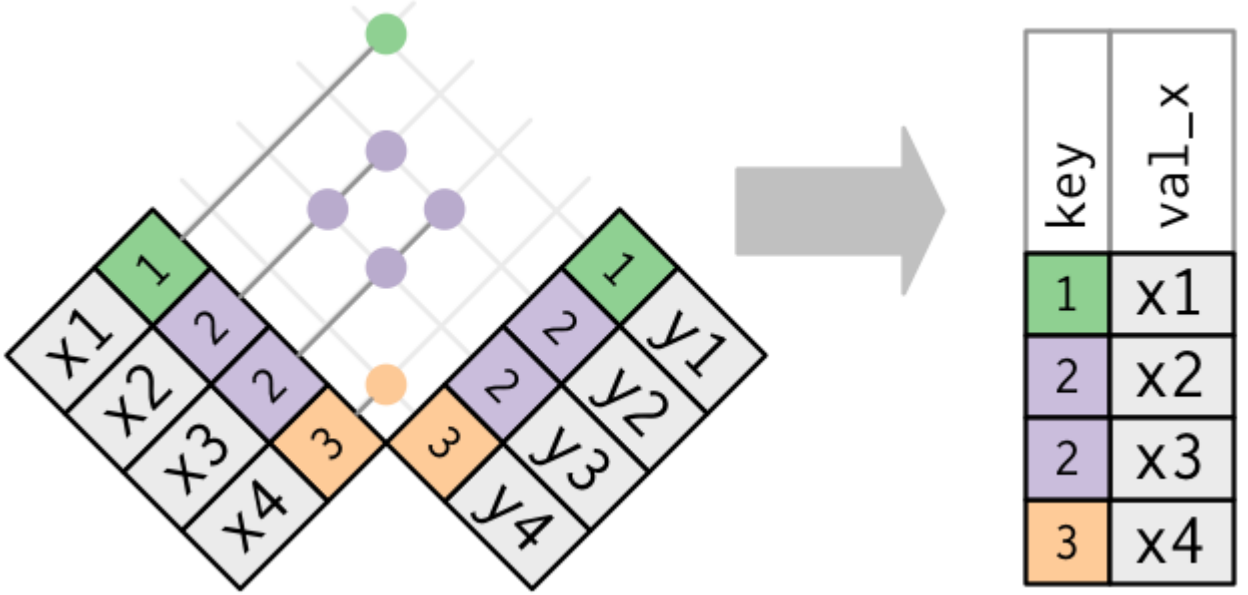

# anti_join

`anti_join(x,y)` só retorna elementos de `x` que **não** estão em `y`. É útil para detectar se há chaves faltantes em uma tabela.

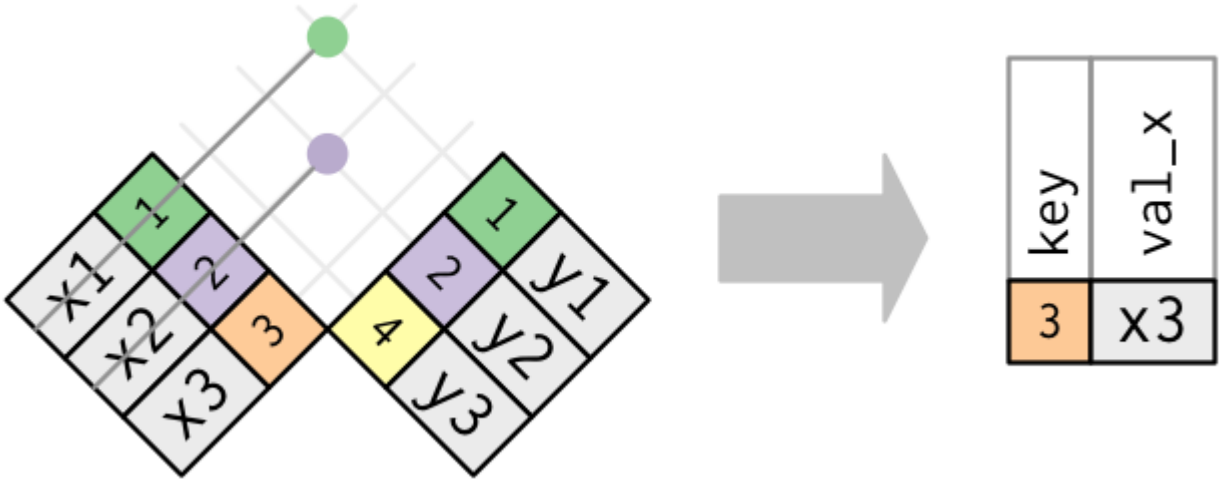


```
all.equal(x %>% anti_join(y,  by = "key"),
          x %>% filter(!(key %in% y$key)))
```

```
## [1] TRUE
```

# Referência

- R for Data Science - https://r4ds.had.co.nz/