# MongoDB

Benilton Carvalho & Guilherme Ludwig

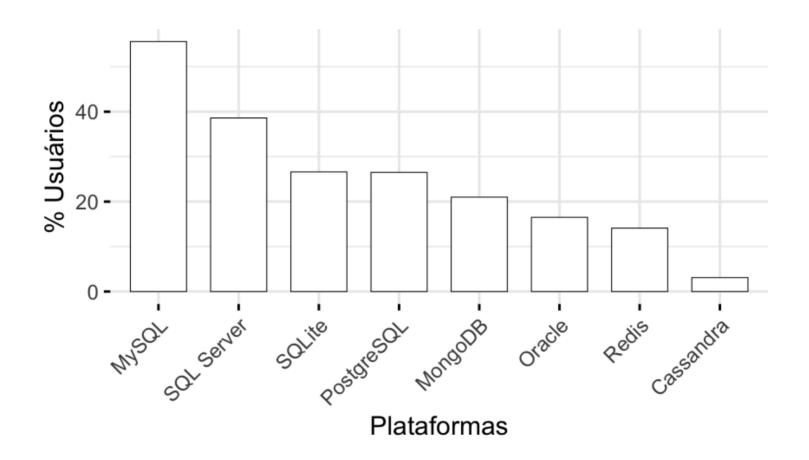
# Introdução ao MongoDB

- Código aberto;
- Gratuito;
- Alta performance;
- Sem esquemas;
- Orientado a documentos;
- Implementado em C++;

#### Orientado a Documentos

- Orientado a documentos JSON;
- Lembrete:
  - o documentos JSON possuem estrutura hierárquica;
  - podem ser facilmente utilizados pelo R ou outras ferramentas para realização de analítica;
  - o suportam hierarquias complexas e mantém índices;

#### Popularidade no StackOverflow em 2017



#### **Efeitos Práticos**

- Cada documento é autossuficiente;
- Cada documento possui todas as informações de que possa precisar;
- Lembrete:
  - em SQL, evitam-se repetições e combinam-se tabelas via chaves;
- Evitam-se JOINs;
- Desenha-se a base de dados de forma que as *queries* busquem apenas uma chave e retornem todas as informações necessárias;
- Preço: espaço em disco;

#### Utilização de MongoDB

- Foco em big data;
- Escalonamento horizontal (sharding) desempenho;
- Escalonamento vertical (*replica sets*) multicore;
- Se os dados não possuem formato fixo, MongoDB é uma boa opção;
- (J/B)SON não possuem esquemas;
- Opção natural para sistemas web. Exemplo: Comércio eletrônico detalhes de produtos;

#### Quando não utilizar MongoDB?

- Quando relacionamentos entre múltiplas entidades for essencial;
- Quando existirem múltiplas chaves externas e JOINs;
- Expectativas em MongoDB:
  - Documentos autossuficientes;
  - Mínimo de chaves;
  - etc;

#### Disponibilidade

- MongoDB Atlas Database as a Service (AWS, GCP, Azure);
- Linux;
- MacOS;
- RHEL;
- Windows;

#### Uso do pacote mongolite

- Sempre monta-se uma conexão via mongo();
- O arquivo pode ser remoto ou local;
- Contagem de registros via con\$count();
- Remoção de coleção via con\$drop();

## \$ writeErrors: list()

• Inserção de coleção via con\$insert();

stopifnot(con\$count() == nrow(mtcars))

```
library(tibble)
library(mongolite)
myurl = "mongodb://readwrite:test@mongo.opencpu.org:43942/jeroen_test
con <- mongo("mtcars", url = myurl)
if(con$count() > 0) con$drop()
con$insert(mtcars)

## List of 5
## $ nInserted : num 32
## $ nMatched : num 0
## $ nRemoved : num 0
## $ nUpserted : num 0
```

#### Uso do pacote mongolite

- Seleção de dados presentes no banco de dados fia con\$find();
- No pacote mongolite, remover o objeto de conexão, con, já desconecta a sua sessão do banco de dados;
- Mas também existe o método disconnect() para realizar a desconexão;

```
mydata <- con$find()
stopifnot(all.equal(mydata, mtcars))
con$drop()
rm(con)</pre>
```

#### Coleções Maiores e Seleções mais Complexas

Inserção de um conjunto de dados mais volumoso;

## \$ nRemoved : num 0
## \$ nUpserted : num 0
## \$ writeErrors: list()

```
library(nycflights13)
## subconjunto pq o servidor eh publico
flights = flights[sample(nrow(flights), 10000), ]
m <- mongo(collection = "nycflights", url=myurl)
m$drop()
m$insert(flights)

## List of 5
## $ nInserted : num 10000
## $ nMatched : num 0</pre>
```

#### Seleções mais Complexas

- find() é análogo ao SELECT \* FROM tabela;
- É possível ordenar os dados já na seleção;
- As chamadas devem acontecer usando formato JSON;

```
m$count('{"month":1, "day":1}')
## [1] 19
jan1 <- m$find('{"month":1,"day":1}', sort='{"distance":-1}')</pre>
head(jan1) %>% as_tibble()
## # A tibble: 6 x 19
##
  year month day dep_time sched_dep_time dep_delay arr_time
    <int> <int> <int>
                                                <dbl>
                        <int>
                                      <int>
                                                        <int>
##
## 1 2013
              1
                         1720
                                       1725
                                                   -5
                                                         2121
## 2 2013
                                                   32
                                                         2250
                         1937
                                       1905
              1 1
## 3 2013
                                       630
                                                   -2
                     628
                                                         1016
## 4 2013
                         1059
                                       1053
                                                         1342
                                                   6
## 5 2013
                         1730
                                       1730
                                                         2126
## 6 2013
                         1959
                                       2000
                                                   -1
                                                         2310
## # ... with 12 more variables: sched_arr_time <int>, arr_delay <dbl>, _{12}
```

#### Ordenação em Grandes Bases

- Bases volumosas exigem a existência de um índice para permitir a ordenação;
- O índice pode ser adicionado via index();
- find() aceita o argumento sort=.

#### Seleção de Colunas Específicas

- Utiliza-se find();
- Adiciona-se o argumento fields=, que recebe a lista (em JSON) das variáveis de interesse;
- Ao especificar colunas de interesse, o MongoDB retorna uma coluna adicional, \_id, que corresponde a um identificador interno do banco de dados;

```
carrier distance
##
## 1
        ΕV
               266
              2227
## 2
        UA
## 3
        DL
              1096
## 4 UA
              997
## 5
       US
              214
## 6
        DL
              1035
```

# Identificação de Ocorrências Únicas

- O método distinct() retorna o que são valores únicos de um certo campo;
- Ele pode receber condições para serem avaliadas durante a execução;

```
# List unique values
m$distinct("carrier")

## [1] "WN" "AA" "US" "9E" "EV" "MQ" "DL" "UA" "B6" "VX" "FL" "AS" "HA" "YV'
## [15] "00" "F9"

m$distinct("carrier", '{"distance":{"$gt":3000}}')

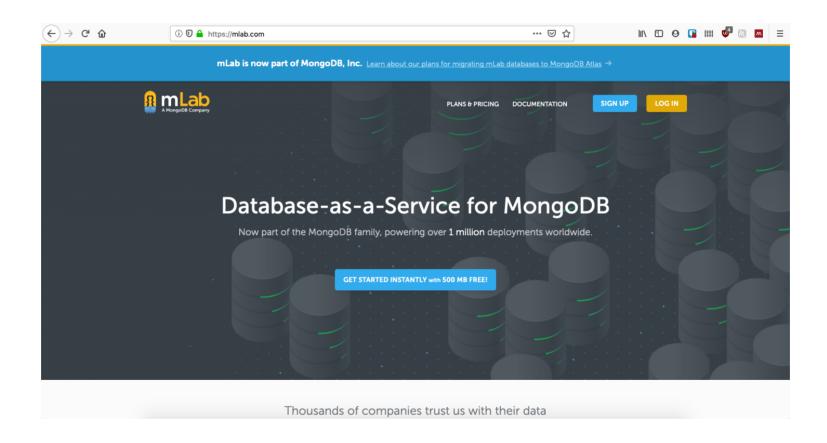
## [1] "UA" "HA"
```

### Tabulação de Dados em MongoDB

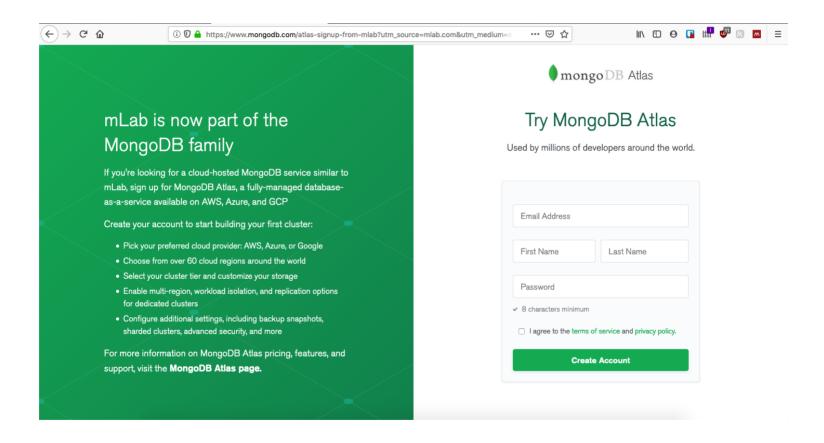
- O método aggregate() permite a tabulação de dados;
- Ele exige, em seu primeiro argumento, a apresentação de um *pipeline* para cálculos desejados;

```
_id count
##
                average
## 1 F9
            14 1620,0000
## 2 00
                453.5000
## 3 AS
         10 2402.0000
     9E
         536 551.2071
## 4
## 5
     US
         632 572.6487
## 6
     HA
             9 4983.0000
## 7
      AA
          1024 1362.7559
## 8
      WN
         359 995.4624
      VX
         149 2507.6510
## 9
         11 343.5455
## 10
      Y۷
## 11
      FL
           103 672.7087
```

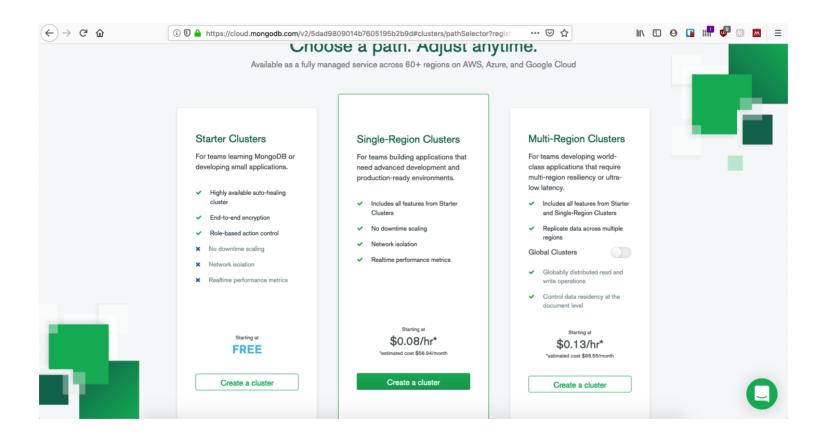
# Criando sua instância para testes: mlab.com



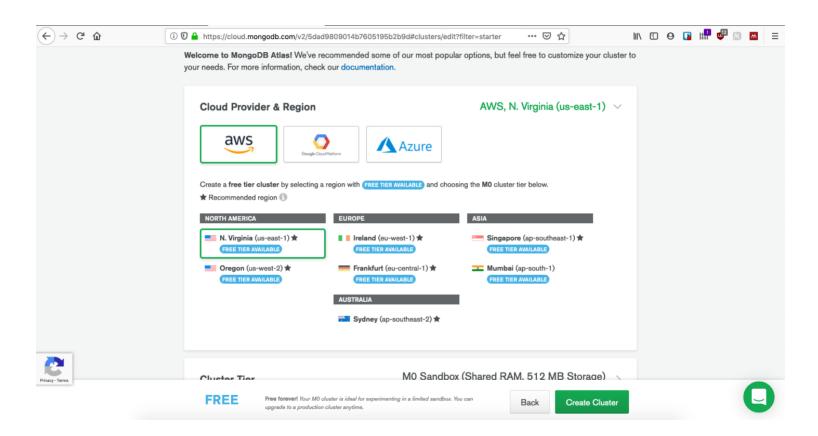
#### Criando sua instância para testes: CREATE ACCOUNT



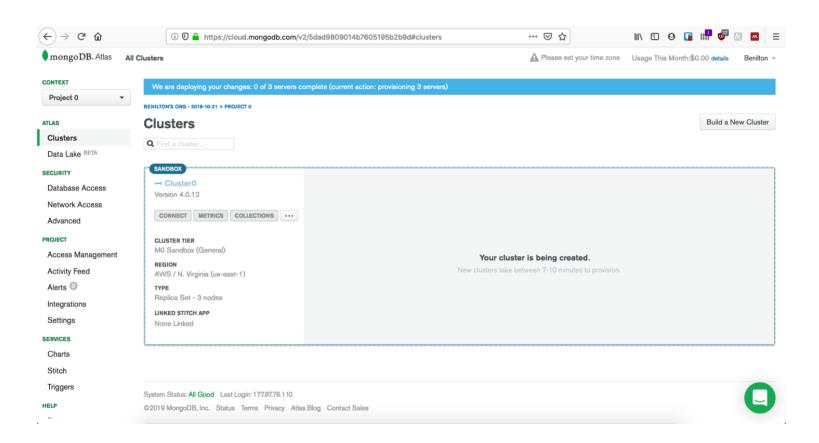
#### Criando sua instância para testes: FREE



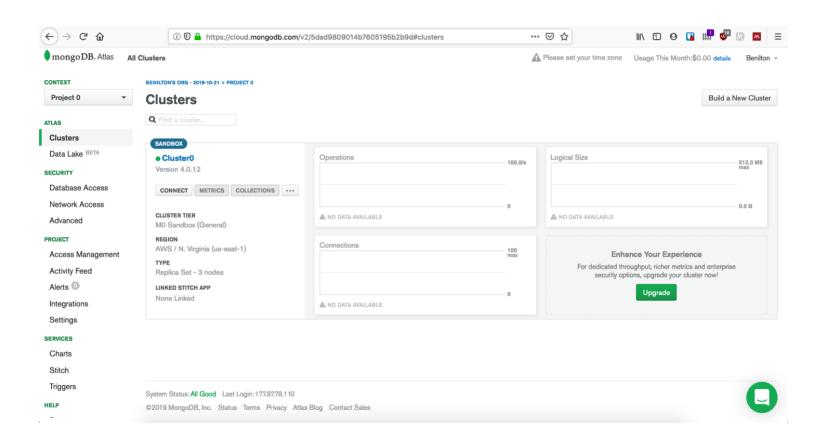
### Criando sua instância para testes: CREATE



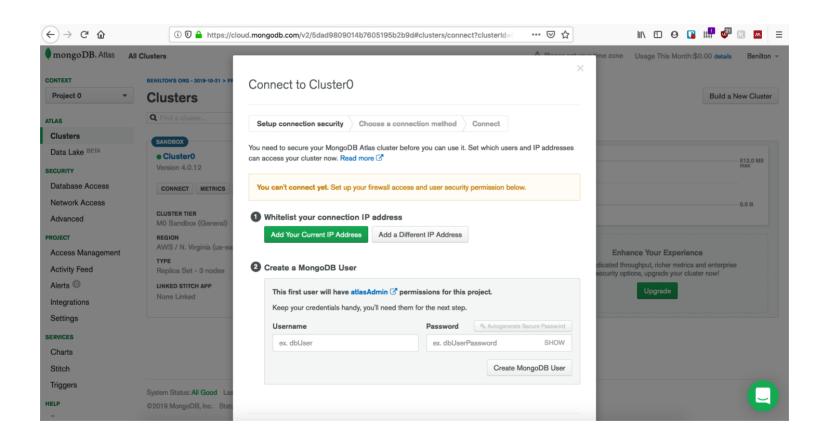
# Criando sua instância para testes: Espere até criação



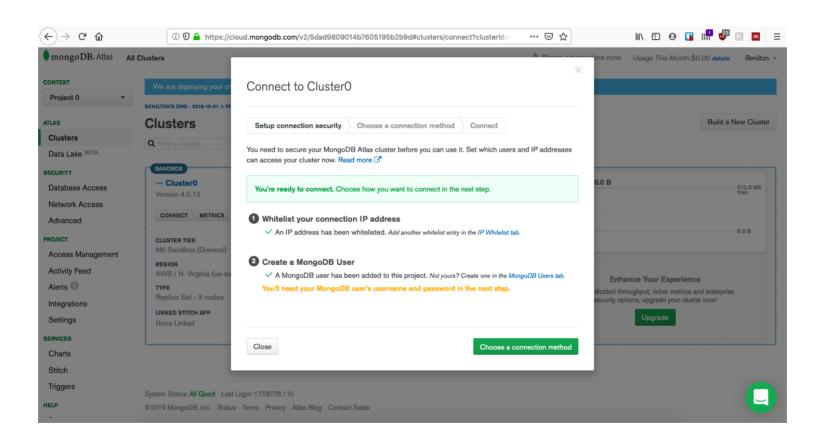
# Criando sua instância para testes: Cluster pronto



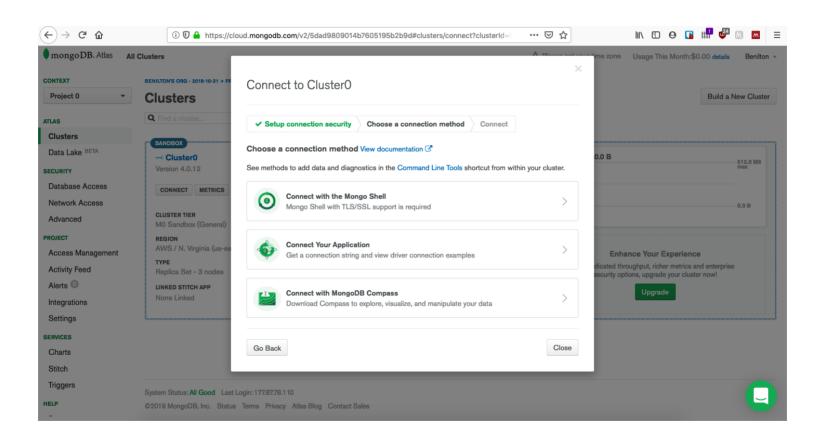
#### Criando sua instância para testes: Acesso



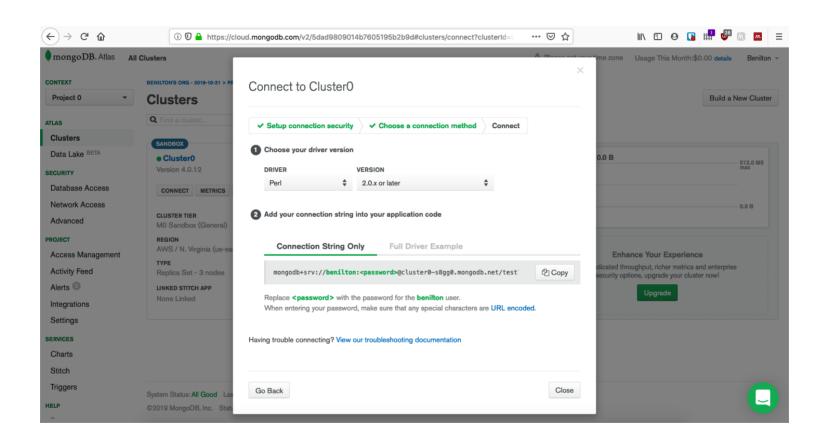
#### Criando sua instância para testes: Conexão



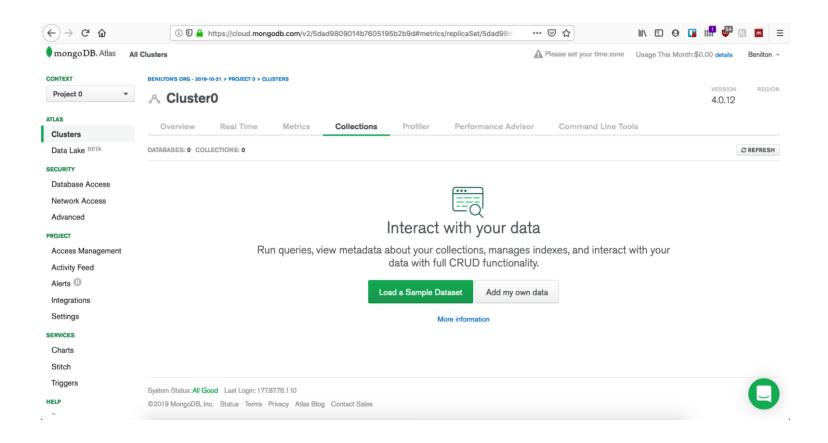
#### Criando sua instância para testes: Application



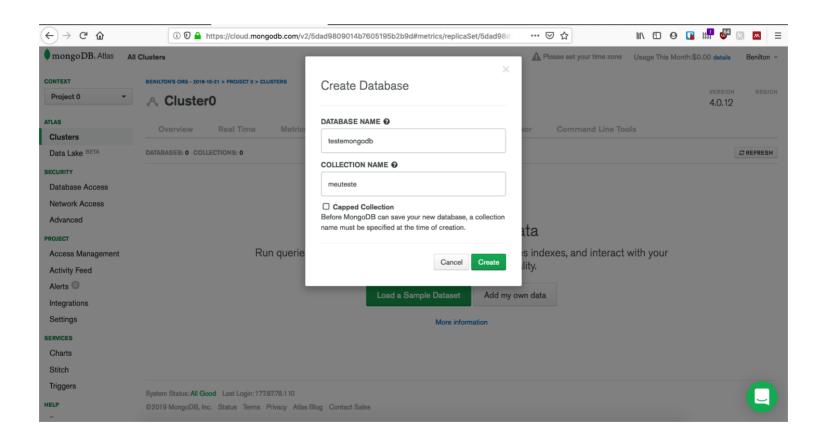
### Criando sua instância para testes: Info para conexão



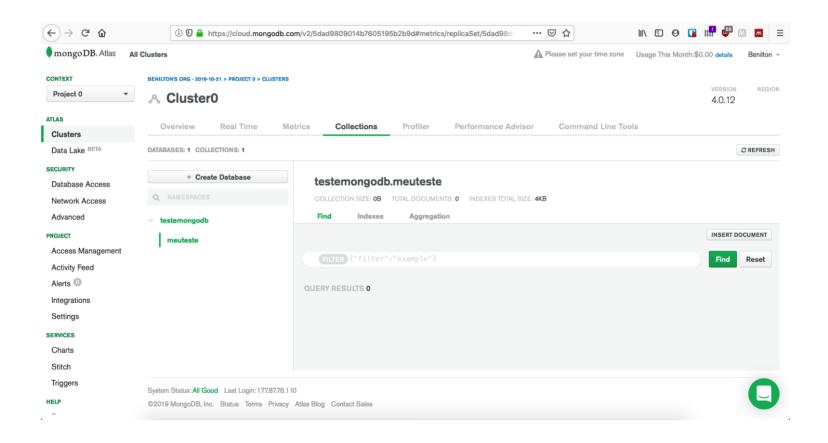
### Criando sua instância para testes: ADD



## Criando sua instância para testes: Banco e coleção

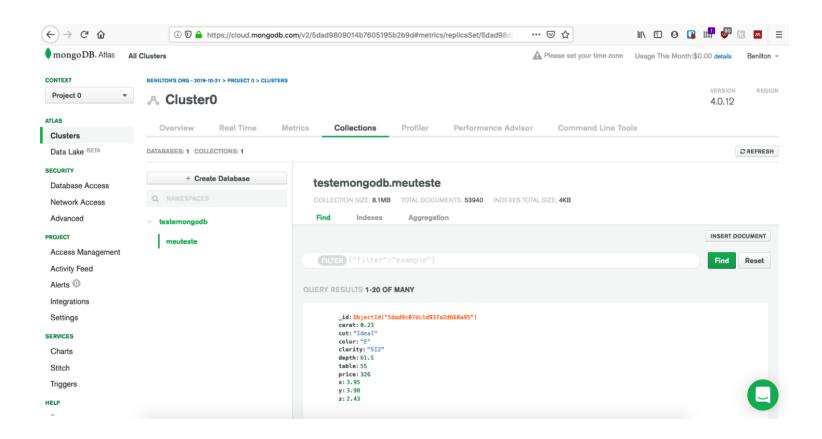


#### Criando sua instância para testes: Estrutura



#### Acesso via R

# Criando sua instância para testes: Dados



### Criando sua instância para testes: Manipulação Extra

